1 Croisements / Inférence

Cet onglet permet de réaliser des croisements soit entre plusieurs variables qualitatives, soit entre plusieurs variables quantitatives, soit entre une variable qualitative et une variable quantitative.

1.1 Croiser deux variables quantitatives

Le croisement de deux variables quantitatives revient à s'intéresser au lien qu'il peut y avoir entre ces deux variables : on parle de corrélation. La corrélation peut-être linéaire (relation de proportion-nalité) ou non-linéaire (ex : L'IMC diminue avec le carré de la taille, et non l'effet simple de la taille.) Les résultats présentés dans l'encadré au centre de la page sont les coefficient de Pearson et de Spearman.

```
Coefficient de corrélation de Pearson

Le coefficient de corrélation linéaire de Pearson (Rho) est estimé à 0.148 et son intervalle de confiance à 95% est: [ -0.056 ; 0.341 ]

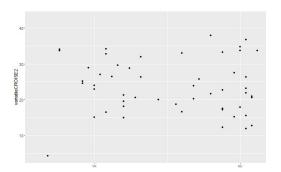
La p.valeur associée au test de nullité de ce coefficient est estimée à: 0.1536

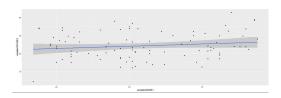
Coefficient de corrélation de Spearman

Le coefficient de corrélation non-paramétrique de Spearman est estimé à: 0.097

La p.valeur associée au test de nullité de ce coefficient est estimée à: 0.3539
```

- Le coefficient de corrélation de **Pearson** est une mesure du degré de corrélation linéaire. Ce coefficient est compris entre -1 (corrélation négative forte) et 1 (corrélation positive forte). Ce coefficient correspond donc à une mesure de la proportionnalité qui peut exister entre ces deux variables. Pour ce coefficient on présente un intervalle de confiance à 95%, ainsi que la p.valeur associée au test de nullité de ce coefficient. (Une p.valeur inférieure à 0.05 traduit donc une corrélation significativement non-nulle entre les variables quantitatives).
- Le coefficient de corrélation de **Spearman** est une mesure du degré de corrélation, nonforcément linéaire. Il peut être utilisé pour les corrélations quadratiques, logarithmiques etc... Pour ce coefficient, aucun intervalle de confiance ne peut être calculé de façon simple, mais un test de nullité de ce coefficient peut tout de même être réalisé.





On présente également le nuage de points représentant le lien entre les deux mesures quantitatives, ainsi que le graphique comprenant la droite de corrélation (estimée par minimisation des moindres carrés au travers d'un modèle de régression linéaire), afin de représenter graphiquement les résultats obtenus dans la recherche d'une relation de proportionnalité.

1.2 Croiser une variable quantitative et une variable qualitative

Croiser une variable quantitative et une variable qualitative revient à croiser la distribution de la mesure quantitative dans chacun des niveaux de la variable qualitative.

Dans un tableau de valeurs numériques, on reprend ainsi tous les élements descriptifs simples d'une mesure quantitative (moyenne, médiane etc...), mais en les présentant dans une première colonne sur l'ensemble des sujets, puis dans chacun des sous-groupes, donc dans chacune des modalités de la variable qualitative.

```
        VariableCROISE1
        variableCROISE2 = femme
        variableCROISE2 = homme

        Effectifs presents
        94,000
        96,154
        97,778

        Femopartions de présents
        3,000
        96,154
        97,778

        Effectifs manquants
        3,003
        3,846
        2,222

        Moyenne
        54,883
        61,360
        47,523

        Coatt-type
        2,1884
        20,997
        20,763

        Variance
        478,922
        439,215
        431,092

        Freur standard (s.e.m)
        2,234
        2,964
        31,30

        Fr. Std (basée sur l'ANOVA)
        NA
        2,991
        3,146

        Minimum
        17,000
        19,000
        17,000

        Maximum
        94,000
        94,000
        93,000

        Percentile 5
        23,650
        24,459
        23,000

        Q1
        36,750
        50,000
        30,000

        Médiane
        51,000
        59,500
        44,000

        Q3
        75,750
        78,750
        58,550

        Percentile 95
        90,000
        90,550
        86,950

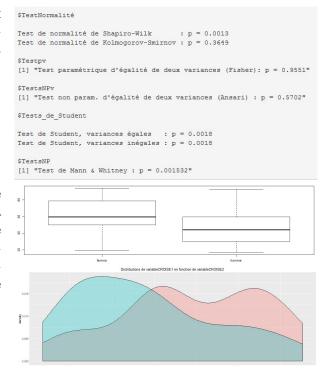
        Percentile 97
        92,550
        86,950
```

Sous ces tableaux sont présentés les résultats des tests associés à la comparaison des mesures dans chacun des sous-groupes. L'utilisateur est ici le seul responsable de l'utilisation des résultats de ces tests.

En effet, sont présentés ici les tests dits de normalité, les tests d'égalité de variances (dont le choix dépend de la normalité) et enfin les tests de comparaisons de moyennes et/ou de distributions (dont le choix dépend des tests précédents).

Graphiques

Les deux graphiques présentés sur cette page sont les diagrammes de type boite (dont la définition est présentée dans l'aide d'une analyse descriptive simple) ainsi qu'un lissage de l'histogramme dans chacun des sous-groupes, afin de comparer les distributions sur les différents niveaux de la variable qualitative.



1.3 Croiser deux variables qualitatives

Le croisement entre deux variables qualitatives est ici réalisé en présentant le tableau croisé de leurs modalités respectives, également appelé tableau de contingence.

Dans notre exemple nous considérons deux variables binaires (Maladie Aigue ou Chronique) et Sexe (Homme ou Femme).

Ainsi, nous retrouvons dans les résultats présentés 4 tableaux.

- Le premier d'entre eux est le **tableau des effectifs** de chacun des sous-groupes. Dans notre exemple, nous retrouvons le nombre Hommes/Chroniques, Femmes Chroniques, Hommes Aigue et Femme Aigue, ainsi que les sommes de chacune des classes.
- Dans le deuxième tableau, on retrouve les **proportions en ligne.** Il s'agit des proportions de chaque colonne, dans le sous-groupe d'une ligne. Dans notre exemple, il s'agit du pourcentage de chroniques et d'aigues dans le sous-groupes des femmes, puis de façon totalement indépendante, les proportions de chroniques et d'aigues chez les hommes.
- Dans le troisième tableau, on retrouve les **proportions en colonne.** Il s'agit désormais d'une lecture verticale de la répartition. Dans notre exemple, on retrouve dans la première colonne la répartition en pourcentages d'hommes et de femmes chez les aigues, puis dans une seconde colonne totalement indépendante, du pourcentage d'hommes et de femmes chez les chroniques.

```
15 52
                    21
          61
                    36 97
[1] "Proportions
                en ligne (en %)'
        aigue chronique
        71.15
                  28.85 100.00
        62.89
                  37.11 100.00
[1] "Proportions en colonne (en %)
        60.66
 homme 39.34
                  58.33
[1] "Proportions du total (en %)
 femme 38.14
                  15.46
                  21.65
                         46.39
        62.89
                  37.11 100.00
       aigue chronique
                  19.3
 homme 28.3
                  16.7
```

- Dans le quatrième tableau, on considère les 4 coupes de possibilités comme 4 classes distinctes, et on présente le **pourcentage de chacune de ces 4 catégories**, la somme des 4 étant de 100%.
- Dans le cinquième tableau, on présente les **effectifs théoriques attendus** sous l'hypothèse d'une indépendance entre les deux variables. Ce tableau est utilisé pour les tests en contrebas.

Les tests d'indépendance ou d'association :

Deux tests d'association entre les variables qualitatives sont ici présentés : le test du Chi2 et le test non-paramétrique exact de Fisher. Le test du Chi2 peut-être utilisé si l'ensemble des effectifs théoriques sont supérieurs à 5. Dans le cas contraire, il est préférable d'utiliser le test non-paramétrique de Fisher. Une p.valeur < 0.05 traduit une association entre les deux variables, ou de façon équivalente leur non-indépendance.

Le rapport de cotes :

Lorsque c'est possible (pour les tableaux à 4 cases) le rapport de cotes et son intervalle de confiance à 95% sont présentés dans les résultats du test exact de Fisher.